Distancia de Fermat en Clasificadores de Densidad por Núcleos

Defensa de tesis de Maestría en Estadística Matemática

Lic. Gonzalo Barrera Borla · Director: Dr. Pablo Groisman

Departamento de Matemática, FCEN, UBA

El problema

Clasificar con densidades

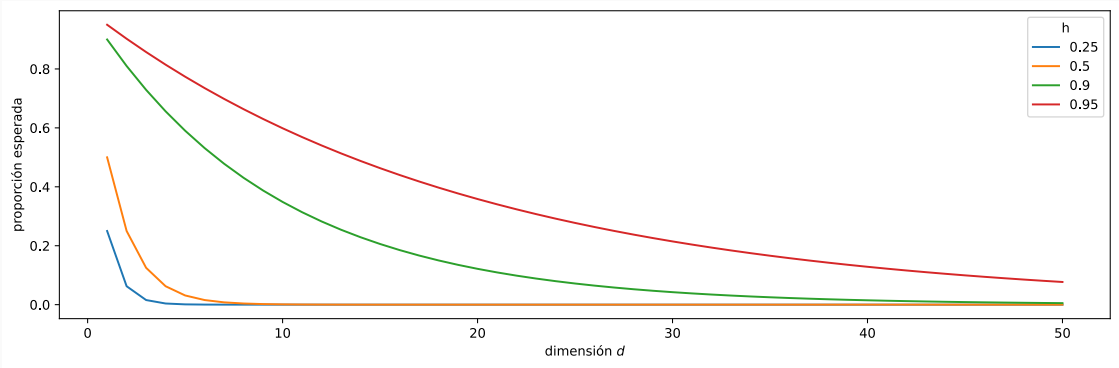
El *clasificador de Bayes* asigna a cada x la clase más probable. Con la regla homónima, también da probabilidades, y por eso un clasificador *suave*:

$$\widehat{\Pr}(G = g_i \mid X = x) = \frac{\hat{\pi}_i \hat{f}_i(x)}{\sum_{k=1}^{K} \hat{\pi}_k \hat{f}_k(x)}$$

Si cada $\hat{f}_k$ es un estimador de densidad por núcleos, $\hat{f}(x) = N^{-1} \sum_i K_h(x - x_i)$, el resultado es el clasificador de densidad por núcleos (`KDC`).

ESL §6.6; Parzen 1962; Wand y Jones 1995

La maldición de la dimensión



Con $X \sim \mathrm{Unif}\big([-1,1]^d\big)$ y una ventana de lado $2h$, la fracción esperada de puntos dentro de la ventana es h^d: para $d = 50$ y $h = 0.95$, menos del 1 %.

Hipótesis de la variedad: los datos en $\mathbb{R}^D$ se concentran cerca de una variedad $\mathcal{M}$ de dimensión $d_{\mathcal{M}} \ll D$.

Densidades en variedades

Pelletier (2005) adapta el estimador a una variedad de Riemann $(\mathcal{M}, g)$ compacta y sin frontera:

$$f_{N,K}(p) = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{h^d} \frac{1}{\theta_{X_i}(p)} K\left(\frac{d_g(p, X_i)}{h}\right)$$

con d_g la distancia de Riemann y θ la densidad de volumen. Loubes y Pelletier (2008) lo usan en la regla de Bayes para clasificar.

Pero la variedad, y con ella d_g, son desconocidas.

La distancia de Fermat

Distancia de Fermat, macroscópica y muestral

Para f positiva y $\beta \geq 0$, la distancia de Fermat minimiza un funcional de caminos:

$$\mathcal{D}_{f,\beta}(x, y) = \inf_{\gamma \in \Gamma} \int_{\gamma} f^{-\beta}$$

Su versión muestral, para $\alpha \geq 1$, se calcula sobre la muestra $\mathbf{X}$:

$$D_{\mathbf{X},\alpha}(x, y) = \inf \left\{ \sum_{j=1}^{K-1} \left\| q_{j+1} - q_j \right\|^{\alpha} : (q_1, ..., q_K) \text{ camino de } x \text{ a } y \right\}$$

y converge: $n^{\beta} D_{\mathbf{X}_n,\alpha} \to \mu \mathcal{D}_{f,\beta}$, con $\beta = (\alpha - 1)/d$.

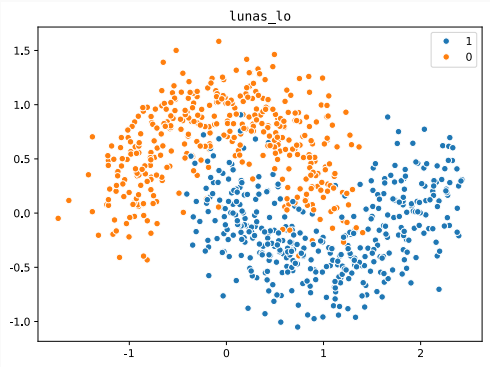
Groisman, Jonckheere y Sapienza (2022); Little et al. (2021)

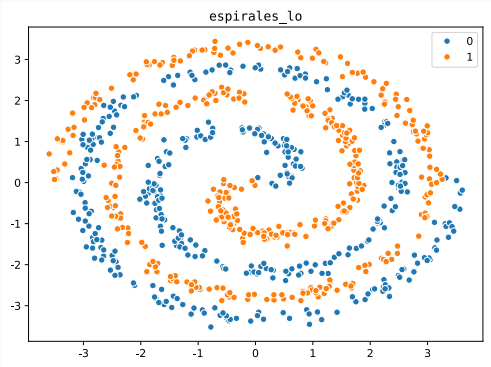
La propuesta: `fKDC` y `fkNN`

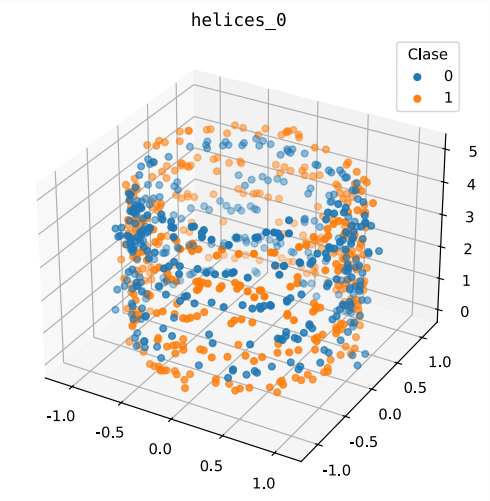
- Para clasificar un punto nuevo x_0, cada clase g_i define $Q_i = \{x_0\} \cup \{x_j : g_j = g_i\}$, y el núcleo se evalúa sobre $D_{Q_i,\alpha}(x_0, \cdot)$ en lugar de la distancia euclídea.
- `fKDC`: el clasificador de Loubes y Pelletier con la distancia de Fermat muestral; hiperparámetros (α, h).
- `fkNN`: k vecinos más cercanos según la misma distancia; hiperparámetros (α, k).
- Con $\alpha = 1$, ambos coinciden con sus pares euclídeos `KDC` y `kNN`.

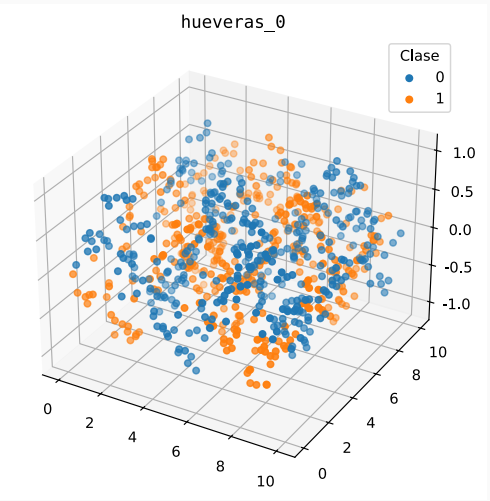
Diseño experimental

20 datasets, 8 clasificadores, 25 semillas







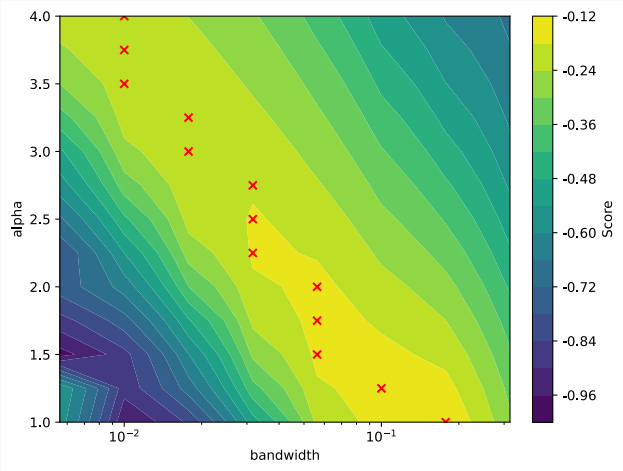


- Sintéticos en variedades (2D y 3D, con ruido bajo y alto, y con 12 dimensiones de ruido), más `anteojos`, `iris`, `vino`, `pinguinos`, `digitos` y `mnist`.
- `fKDC`, `KDC`, `fkNN`, `kNN`, `GNB`, `LR`, `SVC` y `GBT`; partición 50/50 por semilla; grilla por validación cruzada de 5 pliegos con la regla de 1σ.
- Métrica: R^2 de McFadden, $1 - \ell(\mathcal{C})/\ell(\mathcal{C}_0)$, con $\mathcal{C}_0$ las frecuencias de clase; y la exactitud.

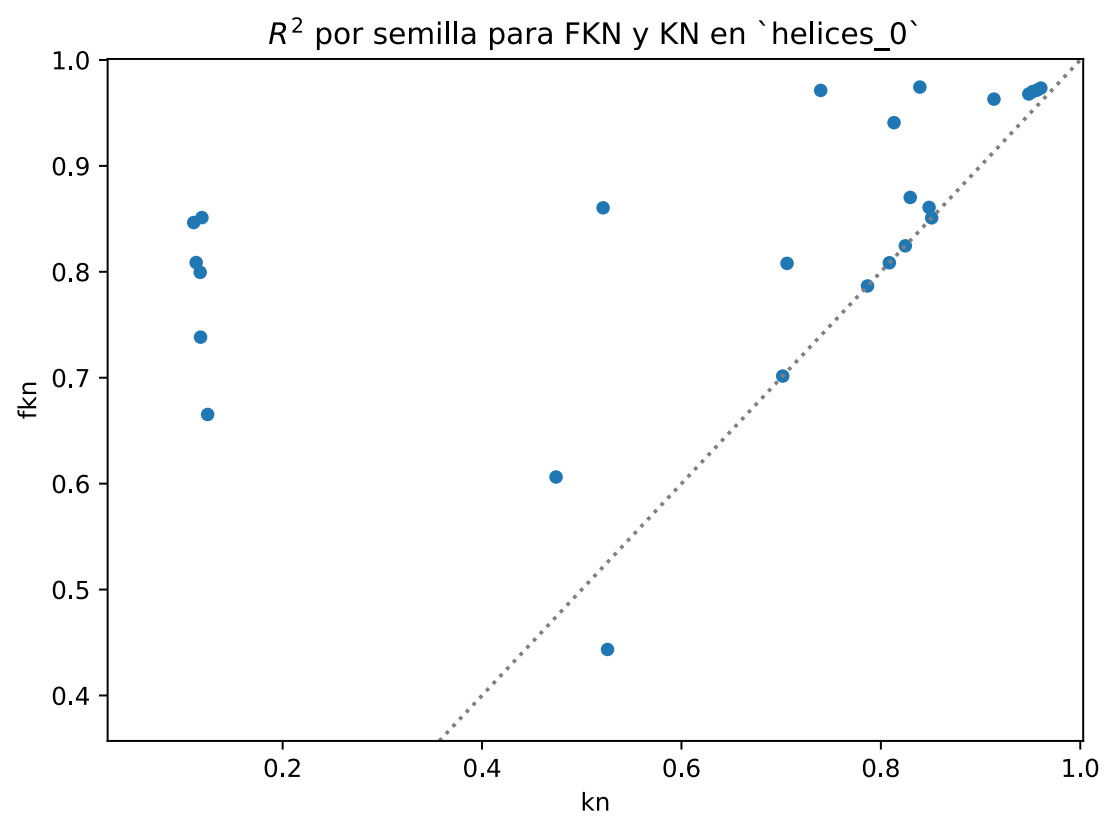
Resultados de la tesis

Podio por R^2 mediano

- `fKDC` obtuvo el máximo en 7 de los 20 datasets y `fkNN` en 5 (dos empatados con `kNN`); `GBT` en 5, `KDC` en 2.
- Por exactitud la ventaja se diluye, y `SVC` resulta casi imbatible.
- En los vecindarios pequeños la distancia de Fermat coincide con la euclídea: en datasets bien muestreados hay un «risco» $\log h \propto \alpha$ de parametrizaciones equivalentes, y la regla de 1σ elige $\alpha = 1$.



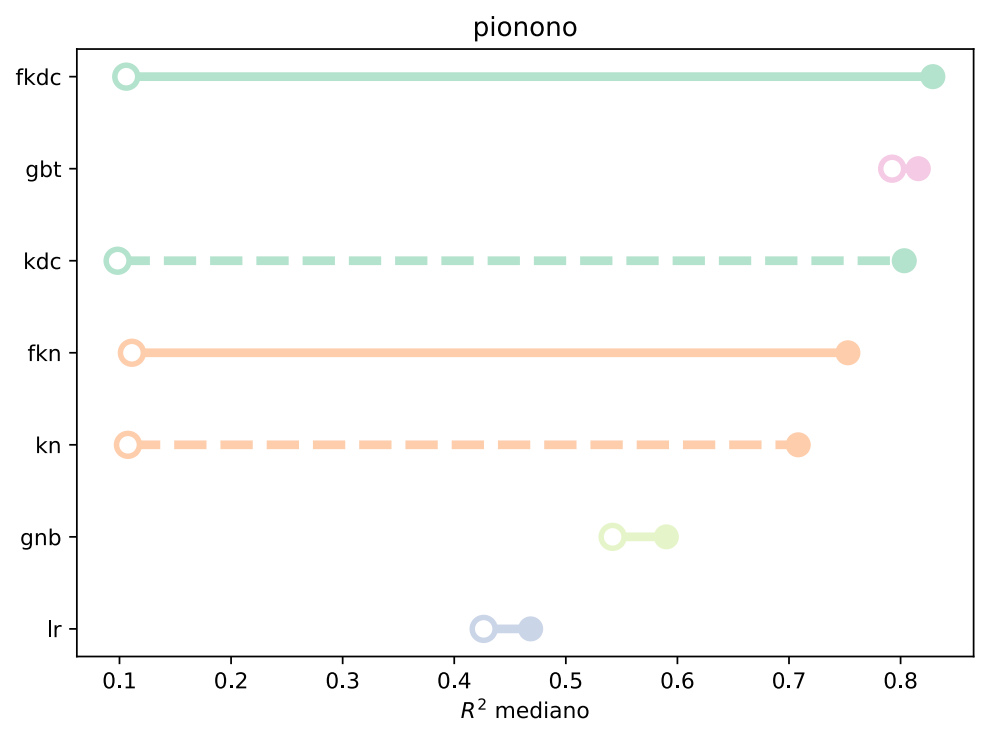
Cuándo aporta: `helices_0`

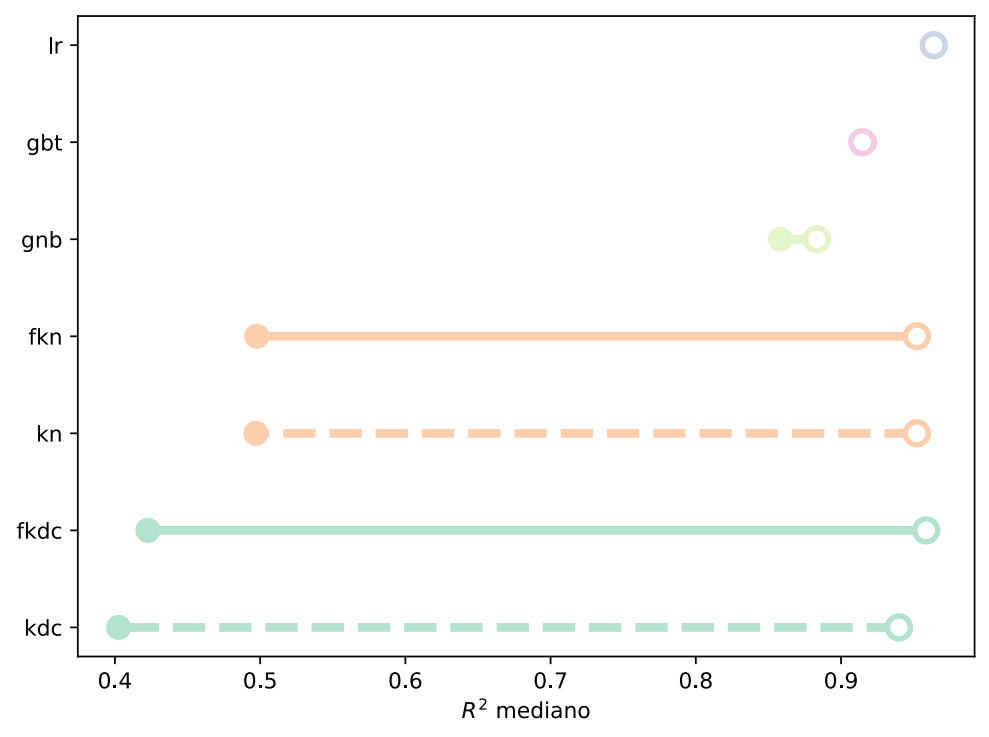


Con el mismo k que `kNN` pero $\alpha > 1$, `fkNN` mejora: la distancia de Fermat permite agrandar el vecindario sin cruzar a la otra hélice.

La mejora es neta, atribuible a la distancia, y no a la interacción entre la regla de parsimonia y una grilla más grande.

Cuándo no: ruido y escala





Con 12 dimensiones de ruido la familia de núcleos se desploma y la distancia de Fermat no lo remedia. La familia tampoco es invariante a la escala: en `pinguinos`, un atributo en gramos bastó para confundir dos especies; estandarizar lo resolvió.

Conclusiones de la tesis

- La distancia de Fermat aporta cuando la variedad es muy curva o está ralamente muestreada: `helices_0` y `hueveras_0`.
- En datasets bien muestreados, α y h son intercambiables y `fKDC` colapsa a `KDC`.
- Las dimensiones de ruido y la escala de los atributos son sus límites.
- Ningún algoritmo fue universalmente óptimo.

Después de la entrega

El trabajo futuro, hecho

La tesis cierra con una lista de pendientes. Tres se pudieron hacer:

Pendiente en la tesis	Lo que se hizo
Reemplazar el recuento de podios por una comparación estadística seria	Wilcoxon de rangos con signo por dataset, con Holm, sobre 100 semillas
Calibrar los clasificadores antes de comparar R^2	R^2 templado: cada clasificador recalibrado por temperatura
Aprender la diagonal $\mathbf{H} \in \mathcal{D}$ en lugar de fijarla	`KDC` con un ancho de banda por variable, elegido por validación cruzada

Además: una réplica prerregistrada con 100 semillas, y la comparación con el estado del arte.

Réplica con 100 semillas, prerregistrada

- Las 25 semillas de la tesis más 75 nuevas; 72 600 tareas, 0 fallas.
- `KDC` exacto: el `KernelDensity` de `scikit-learn` calcula mal las colas profundas, y la tesis lo había usado.
- Grillas emparejadas: la de h de `fKDC` es un subconjunto exacto de la de `KDC`.
- Prerregistro fechado antes de ver resultados: pruebas, márgenes y regla de veredicto.

análisis	replica	no concluyente	no replica	contradice
primaria	117	11	3	1
kdc de sklearn	118	10	3	1
selección ciega a α	113	12	6	1
R^2 templado	106	13	11	2
25 semillas de la tesis	117	14	1	0

132 afirmaciones de la tesis, cada una con su prueba (Wilcoxon apareado con Holm, equivalencia, intervalos).

Qué se sostiene y qué no

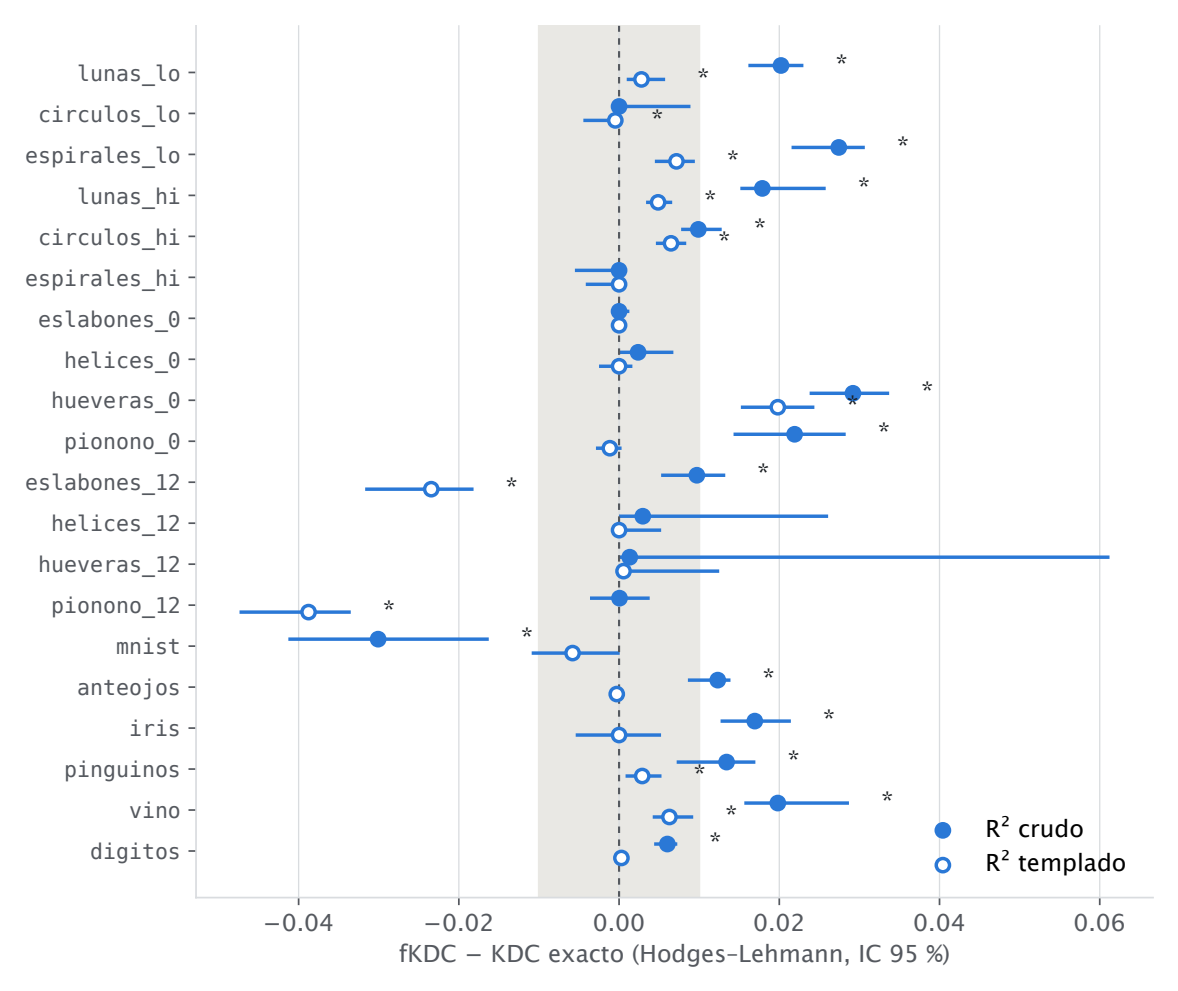
Se sostiene

- `fKDC` > `KDC` en `lunas_lo` (73 semillas a favor, 0 en contra, 27 empates) y en `espirales_lo` (53–11–36).
- `fkNN` > `kNN` en `helices_0` (83–8; +0.16 de R^2) y en `hueveras_0` (61–15).
- El podio casi no cambia: `fKDC` 7, `GBT` 5, `fkNN` 4, `KDC` 3.

No se sostiene

- La ventaja de 5 pp de `fKDC` sobre `KDC` en `helices_0`: con `KDC` exacto, 43–32–25, sin diferencia significativa.
- «La distancia de Fermat aumenta la varianza»: en `helices_0`, `fkNN` tiene menos dispersión que `kNN`.
- «Todos tuvieron al menos un dataset favorable»: `GNB` no tuvo ninguno.

R^2 crudo contra R^2 templado



Diferencia de Hodges–Lehmann `fKDC` − `KDC`, con su intervalo del 95 %; * = significativa con Holm.

Parte de la ventaja de `fKDC` en R^2 es calibración: `KDC` es poco confiado y el exponente α agudiza las probabilidades. En `lunas_lo` y `espirales_lo` la ventaja sobrevive al templado; en `anteojos`, `digitos` y `mnist`, no.

Wilcoxon por dataset: el grupo líder

Clasificador	R^2 crudo	R^2 templado
`fkdc`	17	16
`gbt`	9	6
`fkn`	7	4
`lr`	7	7
`kdc`	5	12
`kn`	4	3
`gnb`	3	7

En cada uno de los 33 datasets, el grupo líder es la mejor mediana más los clasificadores que no difieren significativamente de ella (Wilcoxon de rangos con signo, Holm, $\alpha = 0.05$).

Entre los clasificadores de la tesis, `fKDC` es el que más veces queda en el grupo líder. Con el R^2 templado, `KDC` pasa de 5 a 12: otra vez, calibración.

El estado del arte

TabPFN: la predictiva posterior, aprendida

Un *prior-data fitted network* se entrena una sola vez sobre millones de tablas simuladas de un prior $p(\phi)$:

$$\theta^\star = \arg\min_\theta \mathbb{E}_{\phi\sim p(\phi)} \mathbb{E}_{D,(x_\star,y_\star)\sim p(\cdot \mid \phi)} [-\log q_\theta(y_\star \mid x_\star, D)]$$

Por ser la pérdida logarítmica una regla propia, el óptimo es la predictiva posterior bajo el prior,

$$q_{\theta^\star}(y \mid x, D) \approx \int p(y \mid x, \phi) p(\phi \mid D)\, \mathrm{d}\phi$$

Con una tabla nueva no se ajusta nada: la tabla entra como contexto y la predicción sale de una pasada.

Müller et al. (2022); Hollmann et al. (2023, 2025); Nagler (2023)

El KDC es una cabeza de atención

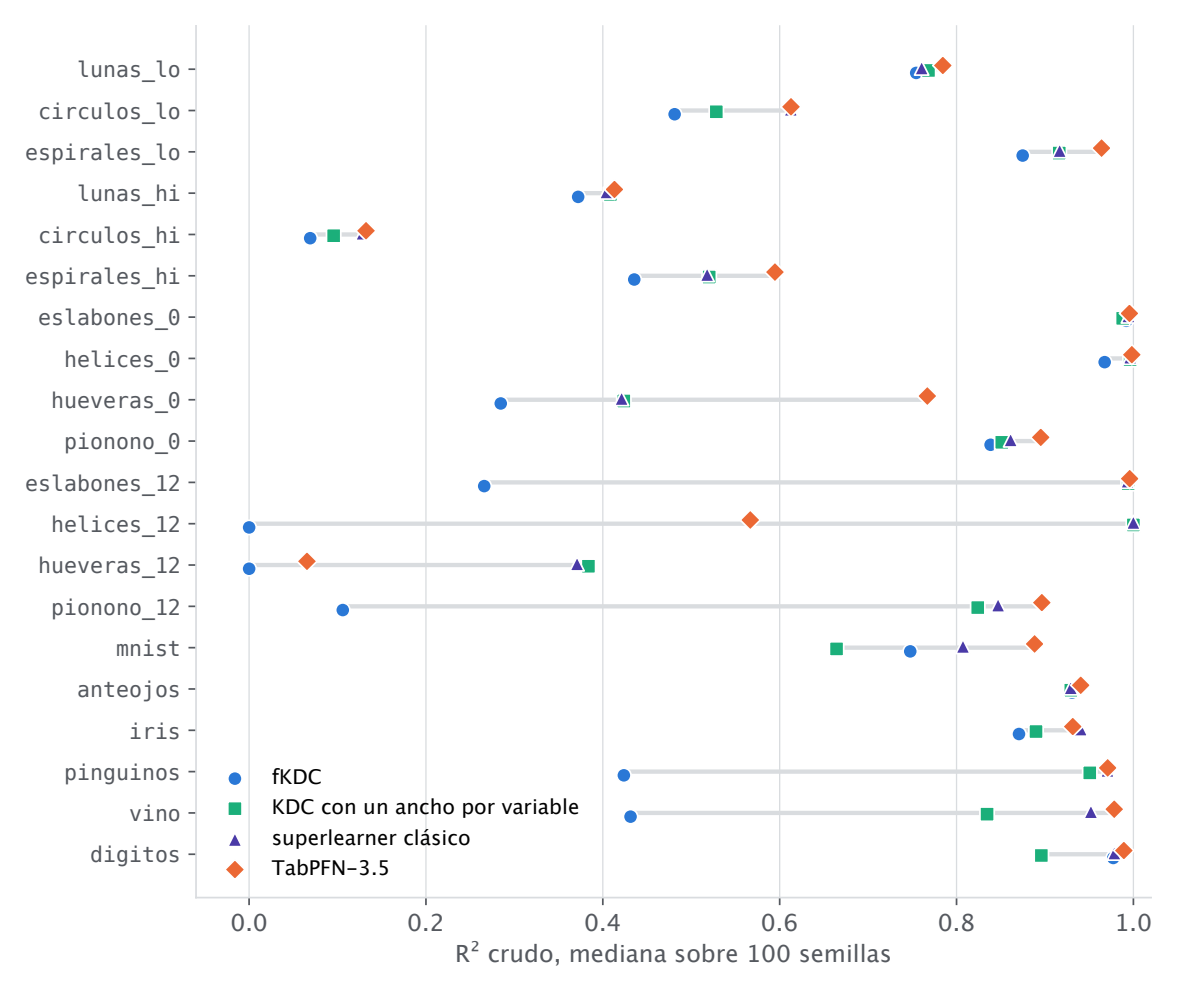
Con probabilidades de clase empíricas, el **KDC** gaussiano es la regresión de Nadaraya–Watson de las etiquetas e_{g_i}:

$$\widehat{\Pr}(\cdot \mid x) = \sum_i \operatorname{softmax}_i \left(-\frac{\|x - x_i\|^2}{2h^2} \right) e_{g_i}$$

y una cabeza de atención de un *transformer* es $\sum_i \operatorname{softmax}_i\left(q^\top k_i/\sqrt{d}\right) v_i$. Con $q = x/h$, $k_i = x_i/h$ y $v_i = e_{g_i}$ (el término en $\|x\|^2$ se cancela en el softmax), son la misma cuenta.

fKDC cambia el núcleo por uno basado en $D_{Q,\alpha}$, fijado por una regla; TabPFN aprende el núcleo, con muchas capas y mirando todas las columnas.

Cuatro métodos, veinte datasets



Mediana del R^2 crudo sobre 100 semillas.

TabPFN-3.5 queda en el grupo líder del conjunto ampliado (22 clasificadores) en 19 de 33 datasets; el superlearner, en 5; `fKDC`, en 2. TabPFN trae un prior aprendido de millones de tablas; los métodos de la tesis aprenden de 400 puntos.

Con dos métodos clásicos, sin redes preentrenadas, se recupera buena parte de la distancia, y en los datasets con ruido se la invierte.

Respuestas clásicas

- KDC con un ancho de banda por variable, elegido maximizando la verosimilitud de $P(y \mid x)$ dejando uno afuera (Hall, Racine y Li, 2004). Es la diagonal $\mathbf{H} \in \mathcal{D}$ del trabajo futuro: las variables irrelevantes reciben anchos grandes y quedan suavizadas. En las variantes con 12 dimensiones de ruido, el menor ancho de una variable de ruido es una mediana de 3.5 a 4.9 veces el mayor ancho de una variable de señal.
- Superlearner: apilamiento convexo, óptimo en log-verosimilitud, de 13 clasificadores clásicos (van der Laan, Polley y Hubbard, 2007). Con 25 semillas, supera a TabPFN en `helices_12` y `hueveras_12` y no es significativamente peor en `circulos`, `eslabones`, `iris` y `pinguinos`.

Lo que da conocer la variedad

dataset	fkdc	tabpfn	lr_oraculo	mejor_oraculo
lunas_lo	0.764	0.787	0.711	0.724
espirales_lo	0.874	0.96	0.955	0.966
helices_0	0.969	0.998	1.0	1.0
hueveras_0	0.285	0.75	0.699	0.806
pionono_0	0.829	0.896	0.883	0.891
helices_12	0.0	0.566	1.0	1.0
hueveras_12	0.0	0.051	0.699	0.806

El oráculo invierte el proceso generador conocido de cada dataset sintético (radio, fase de la espiral, coordenadas del pionono) y ajusta una regresión logística sobre esas coordenadas.

Conocer la variedad vale mucho en `hueveras` y en las variantes con ruido. En `lunas_lo`, `fKDC` supera al oráculo: la inversión es solo aproximada con ese nivel de ruido.

Mediana de R^2 crudo, 25 semillas.

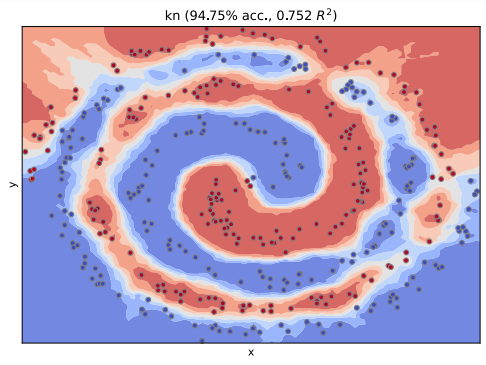
Para seguir

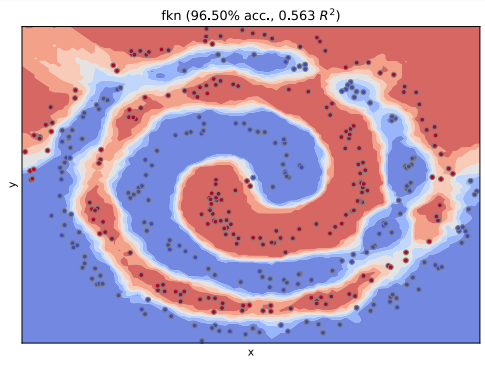
- Localización: según Nagler (2023), el sesgo de un PFN solo se anula si la predicción se localiza alrededor del punto de prueba, y la arquitectura actual no lo garantiza. Los núcleos localizan por construcción.
- Fermat con relevancia: combinar la distancia de Fermat con anchos por variable.
- Teoría: la consistencia del núcleo evaluado sobre la distancia de Fermat muestral sigue abierta.

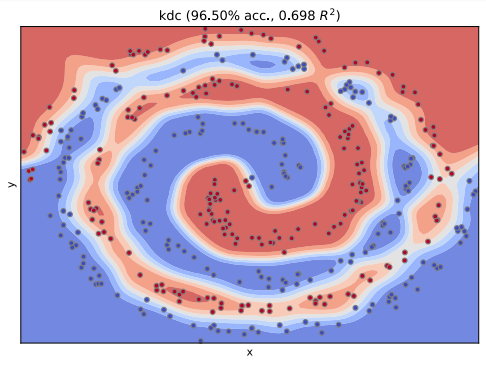
¡Gracias!

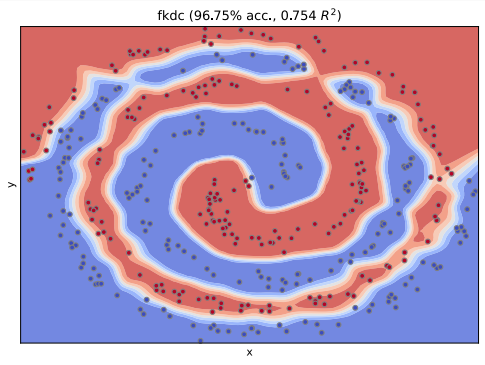
Respaldo

Fronteras de decisión en `espirales_lo`









Método de las comparaciones por dataset

- Unidad: la semilla. En los sintéticos y en `mnist`, cada semilla es una muestra nueva; en los de datos fijos, otra partición 50/50 de los mismos datos, con p-valores optimistas.
- Wilcoxon de rangos con signo, bilateral, sobre las diferencias por semilla; ceros por el método de Pratt; $|\Delta| < 10^{-9}$ es empate.
- Holm dentro de cada dataset: 21 pares entre los 7 clasificadores suaves de la tesis, 190 en el conjunto ampliado.
- Hodges–Lehmann con su intervalo del 95 %; Friedman como prueba ómnibus; prueba bayesiana de rangos con signo con equivalencia práctica de ± 0.01 en R^2.
- R^2 crudo con crudo y templado con templado; las comparaciones mixtas solo descompuestas en sus partes.

Modelos de texto: al azar

- Laya, GLiNER2.5-Decide y una réplica abierta de Jev reciben cada fila como texto, con el nombre del dataset, su descripción o el código que lo genera.
- En todos los regímenes y datasets quedaron en el nivel del azar; ajustado sobre el entrenamiento, GLiNER alcanza la exactitud de `LR` solo en `lunas`.
- Son modelos de un solo paso, sin razonamiento: decidir de qué círculo viene (x_1, x_2) exige calcular $\sqrt{x_1^2 + x_2^2}$ en una pasada.