Preguntas posibles para la defensa

Borrador redactado con asistencia de IA (Claude) a pedido del autor, a partir de la tesis y de los resultados posteriores a la entrega (`sandbox/heroica`, `sandbox/fundacionales`). Las respuestas son puntos de partida: revisarlas y reescribirlas con voz propia antes de usarlas.

1. Sobre el método

¿Por qué la distancia de Fermat y no las geodésicas del grafo de vecinos, como en Isomap?

La distancia de Fermat incorpora la densidad: el funcional $\int_\gamma f^{-\beta}$ abarata los caminos por zonas densas, y su versión muestral converge a la macroscópica (Groisman, Jonckheere y Sapienza). Isomap aprende solo la geometría. Después de la entrega lo probamos: Isomap seguido de k vecinos nunca superó a `fkdc` en las variedades (en `espirales_lo`, R^2 mediano 0.66 contra 0.87).

¿El clasificador `fkdc` es consistente?

No lo sabemos, y la tesis lo dice. Pelletier supone conocida la distancia de Riemann; Groisman et al. garantizan la convergencia de la distancia muestral. Falta un resultado que combine ambos para el núcleo evaluado sobre $D_{Q,\alpha}$. Además, tomamos la densidad de volumen $\theta \equiv 1$ con un argumento cualitativo.

¿Por qué α y h se solapan?

Localmente, la distancia de Fermat muestral es proporcional a la euclídea, y el núcleo se evalúa sobre d/h: lo que α cambia en d se puede compensar con h. En datasets bien muestreados aparece un «risco» $\log h \propto \alpha$ de parametrizaciones equivalentes, y la regla de 1σ elige $\alpha = 1$. Solo cuando la curvatura es comparable a la separación entre observaciones (`helices_0`, `hueveras_0`) aparece un $\alpha > 1$ que ningún h sustituye.

¿Cómo se evalúa un punto nuevo, si la distancia es muestral?

Para cada clase se agrega el punto a la muestra de esa clase, $Q_i = \{x_0\} \cup \{x_j : g_j = g_i\}$, y se calcula $D_{Q_i,\alpha}(x_0, \cdot)$. El costo es el de caminos mínimos sobre el grafo completo; la tesis propone, como trabajo futuro, el grafo de k vecinos con el k de Chu et al.

¿Por qué el R^2 de McFadden y no la exactitud?

Los clasificadores de la tesis son suaves: el R^2 mide la calidad de las probabilidades, no solo la de la clase elegida. Por exactitud la ventaja de la familia de núcleos se diluye y `SVC` es casi imbatible; la tesis informa ambas.

¿La regla de 1σ no sesga la comparación entre `fkdc` y `kdc`?

Sí, y la tesis lo muestra: en `lunas_lo` y `espirales_lo` la ventaja de `fkdc` viene de la interacción entre la regla de parsimonia y la grilla ampliada. En la réplica con 100 semillas guardamos la grilla completa y derivamos también una selección ciega a α: 113 de 132 afirmaciones replican con ella, contra 117 con la regla de la tesis.

2. Sobre los resultados

¿La ventaja de `fkdc` sobre `kdc` en R^2 es real o es calibración?

En parte es calibración: `kdc` es poco confiado, y el exponente α agudiza las probabilidades. Con el R^2 templado (cada clasificador recalibrado por temperatura), la ventaja desaparece en `anteojos`, `digitos` y `mnist`, pero sobrevive en `lunas_lo` y `espirales_lo`. Comparamos siempre crudo con crudo y templado con templado.

¿Qué pasó con el error de `KernelDensity`?
Decirlo antes de que lo pregunten. El `KernelDensity` de `scikit-learn` calcula mal las log-densidades en las colas profundas, y la tesis lo usó para `kdc`. Con un `kdc` exacto, la ventaja de 5 pp de `fkdc` en `helices_0` deja de ser significativa (43–32–25); `fkdc` y `fkn` nunca usaron ese código, así que solo cambian las comparaciones contra `kdc`. Con 100 semillas y `kdc` exacto, la ventaja de `fkdc` en `lunas_lo` y `espirales_lo` se sostiene.

¿Las semillas son observaciones independientes?
En los datasets sintéticos y en `mnist`, sí: cada semilla es una muestra nueva. En `iris`, `vino`, `pinguinos`, `digitos` y `anteojos`, cada semilla es otra partición de los mismos datos, y los p-valores salen optimistas; esos datasets se leen de forma descriptiva.

¿Por qué no estandarizar siempre?
Porque depende de los datos: en `pinguinos` (gramos frente a milímetros) estandarizar llevó a `fkdc` de 0.42 a 0.96 de R^2; en `digitos`, de escala homogénea, lo empeoró de 0.98 a 0.87. Después de la entrega probamos la generalización natural: aprender un ancho de banda por variable (la diagonal $\mathbf{H} \in \mathcal{D}$ del trabajo futuro).

¿Qué se puede hacer con las dimensiones de ruido?
Con un ancho por variable elegido por verosimilitud dejando uno afuera (Hall, Racine y Li, 2004), las variables de ruido reciben anchos de 3.5 a 4.9 veces mayores que las de señal y quedan suavizadas: en `helices_12`, el R^2 pasa de 0 a 1.

¿Por qué 25 semillas?
Por costo. La réplica muestra que varias afirmaciones estaban al límite: para `espirales_lo` hacían falta unas 95 semillas para un 80 % de potencia. Por eso la réplica usó 100, con el prerregistro fijado antes de mirar resultados.

3. Sobre el contexto

¿Por qué no compararon con métodos modernos, como TabPFN?
En la tesis no; después de la entrega, sí. TabPFN-3.5 queda en el grupo líder en 19 de 33 datasets; `fkdc`, en 2 dentro de ese conjunto ampliado. TabPFN trae un prior aprendido de millones de tablas simuladas: aproxima la predictiva posterior bayesiana. Los métodos de la tesis aprenden de 400 puntos.

Si TabPFN gana, ¿para qué sirve la distancia de Fermat?
Para entender y para garantizar. `fkdc` hace explícita la geometría que usa, no depende de un prior simulado ni de pesos preentrenados, y localiza por construcción. Nagler (2023) muestra que el sesgo de un PFN solo se anula si la predicción se localiza alrededor del punto de prueba, y que la arquitectura actual no lo garantiza. Además, métodos clásicos con anchos por variable o un superlearner superan a TabPFN en los datasets con ruido.

¿TabPFN es consistente?
No hay una garantía general: la red está fija y su sesgo no tiene por qué desaparecer con n. Su fortaleza es la optimalidad bayesiana promedio bajo su prior, con muestras chicas.

¿Cuándo recomendaría `fkdc` o `fkn`?
Con variedades muy curvas o ralamente muestreadas, atributos en una escala común y pocas dimensiones de ruido. `fkn` tiene una ventaja práctica: es robusto a la elección de k, porque la distancia de Fermat permite agrandar el vecindario sin cruzar a otra variedad.